

Ансамбль:

$$y_T = \sum_{t=1}^T g_t(x)$$

ансамбль

g_t — слабый классификатор

$g(\omega_t, x)$

Идея Бустинга:

- 1) строить модель
- 2) оценивать её ошибку
- 3) строить новую модель, которая минимизирует ошибку первой
- 4) ...

Пример: минимизация кв. потерь в регрессии

$$\omega_1 = \arg \min_{\omega \in \mathbb{R}^d} \left[\frac{1}{2} \sum_{i=1}^n (g(\omega, x_i) - y_i)^2 \right]$$

$$\bullet \text{ ошибка модели } \omega_1: e_{1,i} = y_i - g(\omega_1, x_i)$$

$$\bullet \omega_2 = \arg \min_{\omega} \left[\frac{1}{2} \sum_{i=1}^n (g(\omega, x_i) - e_{1,i})^2 \right]$$

→ замещаемся

$$e_{t,i} = y_i - \sum_{\tau=1}^t g(\omega_\tau, x_i)$$
$$\omega_{t+1} = \dots$$

NB у нас есть правило как выбирать модель: минимизация и проверка

NB На самом деле мы решаем другую задачу

Сформулируем задачу

$$\sum_{i=1}^n L\left(\underbrace{\sum_{t=1}^{T-1} g_t(x_i)}_{\text{функция}} + \underbrace{g_T}_{\text{мы ищем argmin}}; y_i\right) \quad \Bigg| \quad \text{Будем:} \quad \sum_{i=1}^n L\left(g_T; y_i - \sum_{t=1}^{T-1} g_t(x_i)\right)$$

Зададим now $g(\omega, \cdot)$ и сформируем

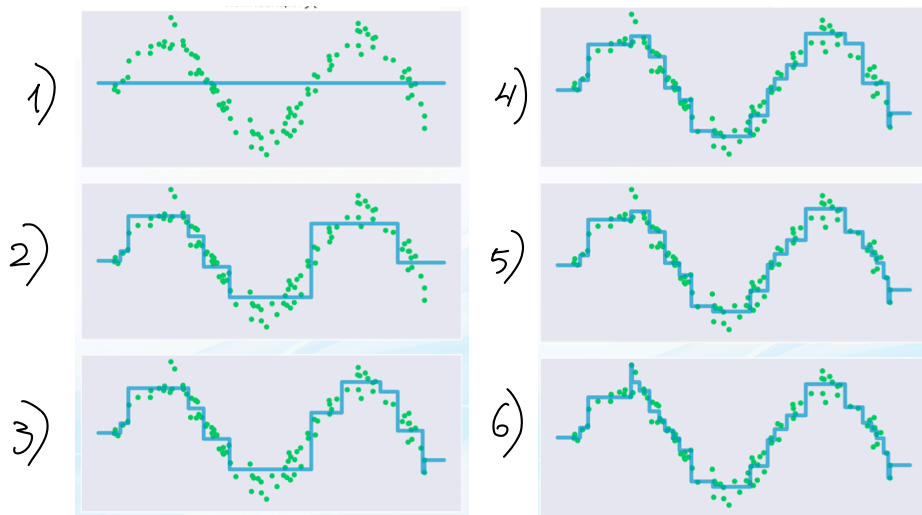
$$\min_{g_i \in \mathbb{R}} \underbrace{\frac{1}{2} \sum_{i=1}^n (g_i - y_i)^2}_{L(g_1 \dots g_n)}$$

$$\nabla_{g_i} L = g_i - y_i = e_i$$

Векторы, мы можем, переходя на всех y_i

Получаем, мы хотим на $-\nabla L$

- мы хотим против градиента \Rightarrow идти к min
- минимизировать теперь новый функционал



много много функций = переобучение

Алгоритм бэггинга:

$$y_T(x) = \sum_{t=0}^T \gamma_t g_t(x) \quad \leftarrow g(\omega_t, x)$$

$t=0$ - создан базовый модель

- $\gamma_0 = 1$
- g_0 - очень простая
 - $g_0(x) \equiv 0$
 - максимизация:
 - $g_0(x) \equiv$ самый простой
 - регрессия:
 - $g_0(x) \equiv \frac{1}{n} \sum_{i=1}^n y_i$

от 0 к пред. улучшению
Заданы y_i модели:

$$L(g) = \sum_{i=1}^n L(g_i, y_i)$$

$$\min_g L(g)$$

данные имеют шаг шаг

$$g^t = g^{t-1} - \eta \underbrace{\nabla_g L(g^{t-1})}_{\left(\nabla_g L(g_i^{t-1}) \right) \}_{n}}$$

Безопасно не можем

$$\omega^t = \arg \min_{\omega} \sum_{i=1}^n L(g(\omega, x_i); -\nabla_g L(g_i^{t-1}))$$

Остается найти γ_t :

$$\hat{\gamma}_t = \arg \min_{\gamma \in \mathbb{R}} \sum_{i=1}^n L \left(\underbrace{g_i^{t-1}}_{y_{t-1}(x_i)} + \gamma g(\omega_t, x_i); y_i \right)$$

$$\hat{\gamma}_t = 1$$

Следует уменьшить

$$\underbrace{y_t}_{g_i^t}(x_i) = y_{t-1}(x_i) + \underbrace{\eta \hat{\gamma}_t}_{\gamma_t} g(\omega_t, x_i)$$

чем меньше, тем сложнее
меньше и условия легче меньше,
но больше больше

Точный алгоритм:

инициализация: $y_0(x_i) = g_0(x_i)$

for $t = 1 \dots T$

$$1) S_i = -\nabla_g L(g) \Big|_{g=y_{t-1}(x_i)}$$

$$2) \omega_t = \underset{\omega \in \mathbb{R}^d}{\operatorname{argmin}} \underbrace{\sum_{i=1}^n L(g(\omega, x_i), S_i)}_{\text{норме невырожденная вып. функции}}$$

$$3) \hat{\gamma}_t = \underset{\gamma \in \mathbb{R}}{\operatorname{argmin}} \sum_{i=1}^n L(y_{t-1}(x_i) + \gamma g(\omega_t, x_i); y_i)$$

$$4) y_t(x_i) = y_{t-1}(x_i) + \hat{\gamma}_t g(\omega_t, x_i)$$

Универсальный случай:

1) MSE perspective

$$L(z, y) = \frac{1}{2}(y - z)^2 \quad L'_z(z, y) = z - y$$

$$S_i = -(y_{t-1}(x_i) - y_i)$$

2) MAE perspective

$$L(z, y) = |z - y| \quad L'_z(z, y) = \operatorname{sign}(z - y)$$

$$S_i = -\operatorname{sign}(y_{t-1}(x_i) - y_i)$$

3) Классификация $y_i \in \{-1, 1\}$

$$\sum_{i=1}^n \mathbb{I}[y_i z_i < 0]$$

сигнал
и компаратор



• $\log(1 + e^{-a})$ Logit Boost

• $1 - a^2$ Gentle Boost

• $\exp(-a)$ Ada Boost

Ada Boost

$$\sum_{i=1}^n \exp(-y_i z_i)$$

$$\sum_{i=1}^n \exp(-y_i \cdot y_t(x_i)) =$$

$$= \sum_{i=1}^n \exp(-y_i \cdot (y_{t-1}(x_i) + \gamma_t g(\omega_t, x_i)))$$

$$= \sum_{i=1}^n \underbrace{\exp(-y_i \cdot y_{t-1}(x_i))}_{\text{предыдущее}} \cdot \exp(-y_i \gamma_t g(\omega_t, x_i))$$

беспроблемно V_i
беспроблемно $\{-1, 1\}$
много $\{-1, 1\}$
логическая ошибка
непроблемно

$$= \sum V_i \exp(-\gamma_t) \cdot \mathbb{I}[y_i = g(\omega_t, x_i)]$$

$$+ \sum V_i \exp(+\gamma_t) \cdot \mathbb{I}[y_i \neq g(\omega_t, x_i)]$$

$$= \exp(-\gamma_t) \cdot \overbrace{\left(\sum v_i \mathbb{I}[y_i = g(\omega_t, x_i)] \right)}^{\text{Positive}} + \exp(\gamma_t) \cdot \underbrace{\left(\sum v_i \mathbb{I}[y_i \neq g(\omega_t, x_i)] \right)}_{\text{Negative}}$$

приравняем к 0 γ_t :

$$- \exp(-\gamma_t) \cdot \text{Positive} + \exp(\gamma_t) \text{Negative} = 0$$

$$\exp(2\gamma_t) = \frac{\text{Positive}}{\text{Negative}} \quad \gamma_t = \left[\frac{1}{2} \ln \frac{\text{Positive}}{\text{Negative}} \right]$$

нормализуем γ_t :

$$\frac{1}{2} \ln \frac{P+\epsilon}{N+\epsilon} \quad \epsilon \sim \frac{1}{n}$$

$$\exp(-\gamma_t) \cdot P + \exp(+\gamma_t) \cdot N =$$

$$= \sqrt{\frac{N}{P}} \cdot P + \sqrt{\frac{P}{N}} \cdot N = 2\sqrt{PN}$$

$$\omega_t = \underset{\omega \in \mathbb{R}^d}{\operatorname{argmin}} \left[\sum v_i \mathbb{I}[y_i = g(\omega_t, x_i)] + \sum v_i \mathbb{I}[y_i \neq g(\omega_t, x_i)] \right]$$

чтобы убедиться:

$$\sum_{i=1}^n \mathbb{I}[y_i \cdot y_T(x_i) < 0] \leq \sum_{i=1}^n \underbrace{\exp(-y_i \cdot y_T(x_i))}_{V_i^T}$$

$$= \sum_{i=1}^n V_i^{T-1} \cdot \exp(-y_i \gamma_T g(\omega_T, x_i))$$

$$\leq \sum V_i^{T-1} (1 - \gamma^2) \quad \gamma = \min \gamma_t$$